

Engenharia de Software para Modelos de Inteligência Artificial

Prof. Dr. Altino Dantas

Ementa

A disciplina aborda os princípios e práticas de Engenharia de Software aplicados ao desenvolvimento de sistemas baseados em Inteligência Artificial. São explorados o ciclo de vida completo de soluções de IA incluindo definição de problema, aquisição e preparação de dados, desenvolvimento e treinamento de modelos de Machine Learning e Deep Learning, avaliação e validação de desempenho, e implantação em ambientes produtivos. O curso cobre ainda práticas de MLOps e LLMOps, arquiteturas escaláveis e resilientes, integração com sistemas corporativos, monitoramento contínuo e governança de modelos. Também são discutidas metodologias ágeis adaptadas ao contexto de IA, além de aspectos éticos, legais e regulatórios. Os alunos desenvolverão projetos práticos aplicando conceitos avançados para resolver problemas reais.

Conteúdo programático

1. Fundamentos e *framing* de IA como software
2. Dados e pipelines
3. Modelagem e avaliação
4. Engenharia (arquitetura + MLOps/LLMOps)
5. Governança, ética e operação
6. Integração e projeto

Cronograma

21/05/2026	Apresentação da disciplina; Fundamentos e <i>framing</i> de IA como Software
26/05/2026	Dados e pipelines
28/05/2026	Modelagem: ML, Deep Learning e LLMs
02/06/2026	Avaliação, Experimentação e Qualidade
04/06/2026	Feriado
09/06/2026	Arquitetura, MLOps e Deploy
11/06/2026	Governança, Ética e Integração
16/06/2026	Palestras externas
18/06/2026	Apresentação dos projetos

Avaliação

NAI = Nota de atividades práticas individuais

NP = Nota de Projeto por equipe

Nota final = $0,3 * \text{NAI} + 0,7 * \text{NP}$

Referências Bibliográficas

BISHOP, Christopher M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.

BURKOV, Andriy. *Machine Learning Engineering*. [S.l.]: Andriy Burkov, 2020.

CHEN, Cathy; ZHANG, Niall; LIU, J. *Reliable Machine Learning: Applying SRE Principles to ML in Production*. Sebastopol: O'Reilly Media, 2022.

GÉRON, Aurélien. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 3. ed. Sebastopol: O'Reilly Media, 2022.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. Cambridge: MIT Press, 2016.

HUYEN, Chip. *Designing Machine Learning Systems: An Iterative Process for Production-Ready Applications*. Sebastopol: O'Reilly Media, 2022.

LAKSHMANAN, Valliappa; ROBINSON, Sara; MUNN, Michael. *Machine Learning Design Patterns: Solutions to Common Challenges in Data Preparation, Model Building, and MLOps*. Sebastopol: O'Reilly Media, 2020.

MITCHELL, Melanie. *Artificial Intelligence: A Guide for Thinking Humans*. New York: Farrar, Straus and Giroux, 2019.

OECD. *OECD Principles on Artificial Intelligence*. Paris: OECD Publishing, 2019. Disponível em: <https://oecd.ai/en/ai-principles>. Acesso em: 11 abr. 2026.

TREVEIL, Mark et al. *Introducing MLOps*. Sebastopol: O'Reilly Media, 2020.

Referências bibliográficas complementares

Fundamentos de LLMs e Transformers

VASWANI, Ashish et al. *Attention Is All You Need*. In: NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 11 abr. 2026.

BROWN, Tom B. et al. *Language Models are Few-Shot Learners*. In: NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2020. Disponível em: <https://arxiv.org/abs/2005.14165>. Acesso em: 11 abr. 2026.

RLHF e Alinhamento de Modelos

OUYANG, Long et al. *Training language models to follow instructions with human feedback*. In: NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2022. Disponível em: <https://arxiv.org/abs/2203.02155>. Acesso em: 11 abr. 2026.

CHRISTIANO, Paul F. et al. *Deep Reinforcement Learning from Human Preferences*. In: NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2017. Disponível em: <https://arxiv.org/abs/1706.03741>. Acesso em: 11 abr. 2026.

Avaliação de LLMs

LIANG, Percy et al. *Holistic Evaluation of Language Models*. Stanford Center for Research on Foundation Models (CRFM), 2022. Disponível em: <https://arxiv.org/abs/2211.09110>. Acesso em: 11 abr. 2026.

ZHENG, Lianmin et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. 2023. Disponível em: <https://arxiv.org/abs/2306.05685>. Acesso em: 11 abr. 2026.

RAG (Retrieval-Augmented Generation)

LEWIS, Patrick et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2020. Disponível em: <https://arxiv.org/abs/2005.11401>. Acesso em: 11 abr. 2026.

Foundation Models e LLMOps

BOMMASANI, Rishi et al. *On the Opportunities and Risks of Foundation Models*. Stanford Institute for Human-Centered Artificial Intelligence (HAI), 2021. Disponível em: <https://arxiv.org/abs/2108.07258>. Acesso em: 11 abr. 2026.

GOOGLE CLOUD. *MLOps: Continuous delivery and automation pipelines in machine learning*. 2020. Disponível em: <https://cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>. Acesso em: 11 abr. 2026.

Data-Centric AI

NG, Andrew. *A Data-Centric AI Approach to Machine Learning*. 2021. Disponível em: <https://www.deeplearning.ai/the-batch/data-centric-ai-development/>. Acesso em: 11 abr. 2026.

Segurança em LLMs

OPEN WEB APPLICATION SECURITY PROJECT (OWASP). *OWASP Top 10 for Large Language Model Applications*. 2023. Disponível em: <https://owasp.org/www-project-top-10-for-large-language-model-applications/>. Acesso em: 11 abr. 2026.

PEREZ, Ethan et al. *Prompt Injection Attacks and Defenses in Large Language Models*. 2023. Disponível em: <https://arxiv.org/abs/2302.12173>. Acesso em: 11 abr. 2026.